Instituto Federal de Educação, Ciência e Tecnologia do Amazonas -IFAM
Bacharelado em Ciência da Computação
Programação para Análise de Dados
1º Trabalho – Práticas com Formatos de Dados e
Manipulação de Arquivos de Grandes Volumes
Março de 2026

Programação para Análise de Dados

1. Descrição do Trabalho

Este trabalho visa consolidar o conhecimento sobre serialização, compressão, *encoding* e arquiteturas de armazenamento (Linha vs. Coluna, Disco vs. Memória). As duplas devem realizar uma pesquisa teórica aprofundada e uma implementação prática comparativa utilizando um dataset de grande volume fornecido em sala.

2. Estrutura e Apresentação

1. **Preparação Total:** Todas as duplas devem estudar, implementar e preparar a apresentação de **todos** os tópicos e tipos de arquivos listados no enunciado.
2. **Sorteio:** No dia da apresentação, uma dupla será sorteada. Imediatamente após, serão sorteados **pelo menos dois (2) tipos de arquivos** que a dupla deverá apresentar.
3. **Tempo de Pitch:** A dupla terá **15 minutos** para apresentar seus principais tópicos sobre os 2 tipos de arquivo, resultados e conclusões.
4. **Arguição Técnica:**
    - Após a apresentação, será sorteada **outra dupla** para fazer **uma pergunta técnica** sobre o trabalho apresentado.
    - A dupla sorteada para perguntar terá 30 segundos para formular a questão.
    - **Penalidade por Repetição:** Se a pergunta for sobre algo que a dupla já explicou claramente na apresentação, ou se for uma pergunta repetida de apresentações anteriores, a dupla que perguntou **perde 1 ponto** na sua nota final.
    - **Bônus por Pergunta:** Se a pergunta for pertinente, técnica e demonstrar que a dupla arguidora estudou o tema, ela ganha **até 1 ponto de bônus**.
    - A dupla que está apresentando / respondendo à pergunta será avaliada pela qualidade da resposta.

3. Critérios de Pontuação e Rubrica (Total: 10 Pontos)

A nota será composta pelos seguintes critérios:

A: Pesquisa Teórica e Fundamentação (3,0 Pontos)

- **O que será avaliado:** Qualidade do conteúdo no Jupyter Notebook e na fala durante a apresentação.
- **Distribuição da pontuação:**
  - **Origem e Contexto (0,5 pts):** Explicar o "porquê" da criação do formatoe breve histórico (ex: o problema que o Parquet resolveu no Hadoop).
  - **Estrutura e Arquitetura (1,0 pts):** Demonstrar (com diagramas) como o dado toca o disco/memória (ex: Row Groups, Footers, Páginas, Memory Layout).
  - **Encoding e Compressão (1,5 pts):** Explicar tecnicamente os mecanismos usados (ex: *Dictionary Encoding*, *Bit Packing*, diferença Snappy/Gzip/Zstd).

B: Implementação e Análise Prática (4,0 Pontos)

- **O que será avaliado:** Código no Jupyter Notebook e gráficos gerados.
- **Distribuição da pontuação:**
  - **Leitura Seletiva (Projection) (1,0 pts):** Provar com gráficos a diferença de tempo entre ler o arquivo todo vs. ler apenas 1 colunas (nos formatos que suportam isso).
  - **Escrita vs. Leitura (1,0 pts):** Gráfico comparando o tempo de persistir o dataset vs. tempo de carregá-lo.
  - **Tamanho em Disco e Compressão (1,0 pts):** Gráfico comparando o tamanho final do arquivo com diferentes *codecs* (Snappy, Gzip, Zstd) vs. o arquivo de texto original (CSV).
  - **Metadados e RAM (1,0 pts):** Demonstração de leitura apenas dos metadados e gráfico/dados do uso de memória RAM durante o processo (usando psutil ou similar).

C: Qualidade da Apresentação e Defesa (2,0 Pontos)

- **Aferição:** Postura, clareza, rigor técnico e resposta à pergunta da arguição.
- **Pontuação:**
  - **Rigor Técnico (1,0 pts):** Uso correto dos termos da área, fluidez na explicação da arquitetura.
  - **Defesa da Pergunta (1,0 pts):** Capacidade de responder de forma fundamentada e segura à pergunta da dupla sorteada.

D: Formatação e Normas (1,0 Ponto)

- **Aferição:** O arquivo Jupyter Notebook entregue.
- **Critérios:**
  - Entregar no formato Jupyter Notebook (.ipynb) com os resultados das células **já executados** e visíveis. (**Atenção:** Será descontado 3 pontos se o arquivo for entregue sem os resultados, necessitando re-execução).
  - Indicação clara de todas as referências bibliográficas e fontes de pesquisa (links, papers, documentações oficiais utilizadas, assim como utilização de IA).

4. Resumo das Regras de Entrega

1. **Dataset:** Utilizar exclusivamente o dataset consolidado de grandes volumes indicado nos links e escolhido previamente. Indicar link do dataset e características principais (finalidade, volume de dados – linhas x colunas, tipos de dados, período utilizado)
2. **Logística:** Somente **um (1)** integrante da dupla deve anexar o arquivo .ipynb. O segundo integrante deve clicar em "entregar" sem anexar arquivo para que o sistema reconheça a participação e atribua a nota.